

# Latent Space Network Models

Florian Pargent

28.06.2017

- 1 Grundidee des Latent Space Ansatzes
- 2 Beispieldatensatz: Publikationen am Statistikinstitut
- 3 Latent Space Modelle in aufsteigender Komplexität (Anwendung mit dem R Paket latentnet)
- 4 Erweiterung auf nicht binäre Netzwerke
- 5 Modellschätzung
- 6 Identifizierbarkeit der Modellparameter

# Grundidee des Latent Space Ansatzes

# Typische Netzwerk Eigenschaften

- Transitivity
- Homophily
- Community Structure
- Degree Heterogeneity

# Modellierung eines latenten “Social Space”

- Jeder Knoten im Netzwerk wird repräsentiert durch einen Positionsvektor im  $\mathbb{R}^2$  (selten  $\mathbb{R}^3$  oder höher)
- Wahrscheinlichkeit für das Vorliegen einer Kante zwischen zwei Knoten hängt ab vom euklidischen Abstand der beiden Knoten
- Bedingt auf die latenten Positionen der Knoten, sind alle Kanten voneinander unabhängig

Vorteile:

- Modellierbarkeit typischer Charakteristiken von Netzwerken
- Natürliche grafische Darstellung des Netzwerkmodells

## Beispieldatensatz: Publikationen am Statistikinstitut

# Webscraping von der Homepage des Statistikinstituts



LUDWIG-MAXIMILIANS-UNIVERSITÄT MÜNCHEN

FAKULTÄT FÜR MATHEMATIK, INFORMATIK UND STATISTIK  
**INSTITUT FÜR STATISTIK**



Google Benutzerdefinierte 

[www.lmu.de](http://www.lmu.de) | [Fakultät für Mathematik, Informatik und Statistik](#) | [LMU-Portal](#) | [Sitemap](#)

[Startseite](#) > [Forschung](#) > Veröffentlichungen

 drucken

## Veröffentlichungen

Springe zu: [2017](#) | [2016](#) | [2015](#) | [2014](#) | [2013](#) | [2012](#) | [2011](#) | [2010](#) | [2009](#) | [2007](#) | [2005](#) | [2004](#) | [2003](#) | [2001](#)

### 2017

- Brockhaus, Sarah; Melcher, Michael; Leisch, Friedrich; Greven, Sonja (2017)  
**Boosting Flexible Functional Regression Models with a High Number of Functional Historical Effects**  
In: Statistics and Computing, Vol. 27, Nr. 4: S. 913-926
- Janitzka, Silke (2017)  
**On the overestimation of random forest's out-of-bag error**  
(Volltext vorhanden)

#### AKTUELLES

#### INSTITUT

#### PERSONEN

#### FORSCHUNG

- [Projekte](#)
- [Veröffentlichungen](#)**
- [Technical Reports](#)

#### STUDIENINTERESSIERTE

#### STUDIUM

#### PROMOTIONSPROGRAMM


#### STELLEN

#### KONTAKT

#### QUICK LINKS

- LSF SoSe 2017
- Frauenbeauftragte
- Statistisches Beratungslabor
- R-Kurse
- Center for Quantitative Risk Analysis
- Blog stats@lmu
- MSc Data Science
- Bibliothek Wirtschaftswissenschaften & Statistik
- Ausgewählte Abschlussarbeiten
- Institutskolloquium

# Soziomatrix (31 Knoten)





# Latent Space Modelle in aufsteigender Komplexität (Anwendung mit dem R Paket latentnet)


# Latent Position Model (LPM)

$$\log \left( \frac{P(Y_{ij} = 1|Z, x, \beta)}{P(Y_{ij} = 0|Z, x, \beta)} \right) = \sum_{k=0}^p \beta_k x_{kij} - \|Z_i - Z_j\|$$

(Hoff, Raftery, and Handcock 2002)

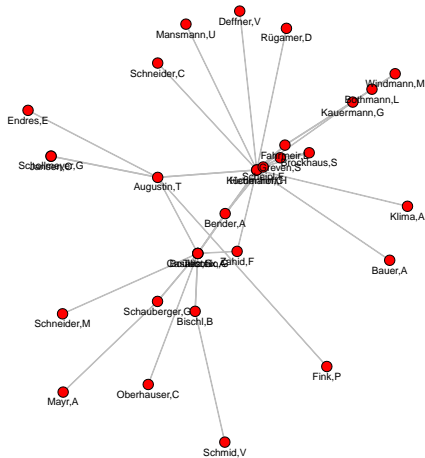
## LPM

network - euclidean( $d = 2$ ,  $G = 0$ )



**LPM**  
network ~ euclidean( $d = 2$ ,  $G = 0$ )

network ~ euclidean(d = 2, G = 0)



# Latent Cluster Model (LCM)


$$\log \left( \frac{P(Y_{ij} = 1|Z, x, \beta)}{P(Y_{ij} = 0|Z, x, \beta)} \right) = \sum_{k=0}^p \beta_k x_{kij} - \|Z_i - Z_j\|$$

$$Z_i \sim \sum_{g=1}^G \lambda_g MVN_d(\mu_g, \sigma_g^2 I_d)$$

(Handcock, Raftery, and Tantrum 2007)

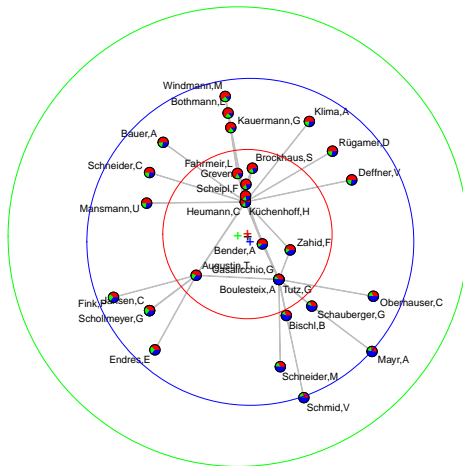
# LCM

network - euclidean( $d = 2$ ,  $G = 3$ )



## LCM

network - euclidean( $d = 2$ ,  $G = 3$ )



# Latent Cluster Random Effects Model (LCREM)

$$\log \left( \frac{P(Y_{ij} = 1 | Z, x, \beta)}{P(Y_{ij} = 0 | Z, x, \beta)} \right) = \sum_{k=0}^p \beta_k x_{kij} - \|Z_i - Z_j\| + \delta_i + \delta_j$$

$$\delta_{i,j} \sim N(0, \sigma_\delta^2)$$


$$Z_i \sim \sum_{g=1}^G \lambda_g MVN_d(\mu_g, \sigma_g^2 I_d)$$

(Krivitsky et al. 2009)



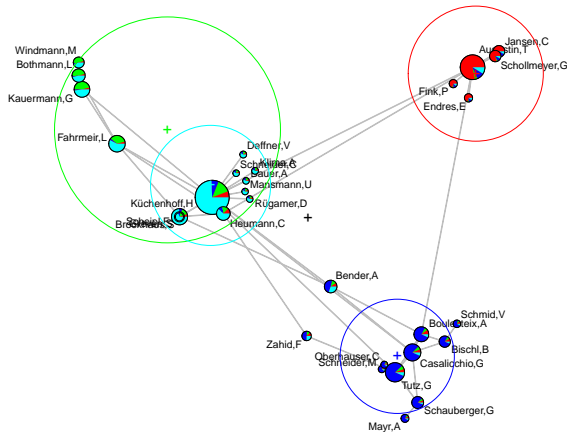
## LCREM

network ~ euclidean(d = 2, G = 4) + rsociality




# LCREM

network ~ euclidean(d = 2, G = 4) + rsociality



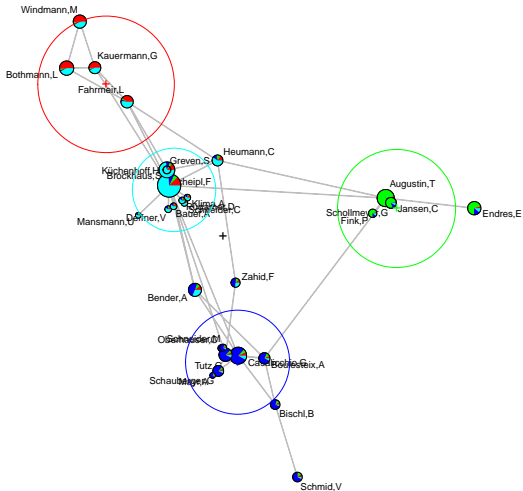
## LCREM mit Kovariable Professoren

network ~ euclidean(d = 2, G = 4) + rsociality + edgecov(zero\_profs) + edgecov(two\_profs)



## LCREM mit Kovariable Professoren

network ~ euclidean(d = 2, G = 4) + rsociality + edgecov(zero\_profs) + edgecov(two\_profs)



## Schätzwerte für $\beta$

	Posterior Mean	2.5%	97.5%
Intercept (Ein Professor)	0.37	-0.32	1.12
Kein Professor	-1.81	-3.42	-0.32
Zwei Professoren	1.40	-0.06	2.93

## Erweiterung auf nicht binäre Netzwerke

$$Y_{ij} | \mu_{ij} \sim \text{Poisson}(\mu_{ij})$$


$$\log(\mu_{ij}) = \sum_{k=0}^p \beta_k x_{kij} - \|Z_i - Z_j\| + \delta_i + \delta_j$$

$$\delta_{i,j} \sim N(0, \sigma_\delta^2)$$

$$Z_i \sim \sum_{g=1}^G \lambda_g \text{MVN}_d(\mu_g, \sigma_g^2 I_d)$$

## LCREM mit Poisson Response und Kovariable Professoren

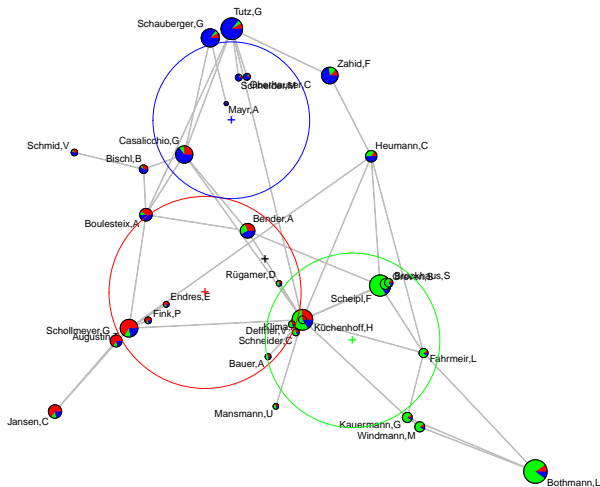
network ~ euclidean(d = 2, G = 3) + rsociality + edgecov(zero\_profs) + edgecov(two\_profs) (Weight)





# LCREM mit Poisson Response und Kovariable Professoren

network - euclidean(d = 2, G = 3) + rsociality + edgecov(zero\_profs) + edgecov(two\_profs) (Weight)



## Schätzwerte für $\beta$

	Posterior Mean	2.5%	97.5%
Intercept (Ein Professor)	0.51	-0.05	1.04
Kein Professor	-1.61	-2.82	-0.42
Zwei Professoren	0.87	-0.25	1.99

# Modellschätzung

# ML Schätzung am Beispiel des LPM

log-Likelihood (vgl. logistische Regression):

$$\log(f(y|\eta)) = \sum_{i \neq j} (\eta_{ij} y_{ij} - \log(1 + e^{\eta_{ij}}))$$

$$\eta_{ij} = \sum_{k=0}^p \beta_k x_{kij} - \|Z_i - Z_j\| = \sum_{k=0}^p \beta_k x_{kij} - d_{ij}$$

Likelihood ist konkav bzgl.  $D$  aber nicht bzgl.  $Z$ .

Deshalb numerische Optimierung:

- Approximiere  $D$  durch geodesische Distanzen
- Identifiziere Positionen  $Z$  aus  $D$  mit multidimensionaler Skalierung
- Verwende  $Z$  als Startwerte für nicht lineare Optimierung (z.b. optim in R)

# Volle Bayes Inferenz am Beispiel des LCM

## Priori Verteilungen

$$\beta \sim MVN_{p+1}(\xi, \Psi)$$

$$\lambda \sim Dirichlet(\nu)$$

$$\mu_g \sim MVN_d(0, \omega^2 I_d)$$

$$\sigma_g^2 \sim \sigma_0^2 Inv\chi_\alpha^2$$

## Full Conditionals (bekannt bis auf Konstanten)

$$z_i | K_i, \dots \propto \phi_d(z_i; \mu_g, \sigma_g^2 I_d) f(y | Z, x, \beta)$$

$$\beta | Z, \dots \propto \phi_{p+1}(\beta; \xi, \Psi) f(y | Z, x, \beta)$$

## Full Conditionals (bekannt)

$$\lambda | \dots \sim \text{Dirichlet}(m + \nu)$$

$$\mu_g | \dots \sim \text{MVN}_d \left( \frac{m_g \bar{z}_g}{m_g + \sigma_g / \omega^2}, \frac{\sigma_g^2}{m_g + \sigma_g^2 / \omega^2} I \right)$$

$$\sigma_g^2 | \dots \sim (\sigma_0^2 + d s_g^2) \text{Inv}\chi_{\alpha + m_g d}^2$$

$$P(K_i = g | \dots) = \frac{\lambda_g \phi_d(z_i; \mu_g, \sigma_g^2 I_d)}{\sum_{r=1}^G \lambda_r \phi_d(z_i; \mu_r, \sigma_r^2 I_d)}$$

# MCMC Algorithmus

## Metropolis-Algorithmus für $Z_{t+1}$ (zufällige Reihenfolge)

- Vorschlag:  $Z_i^* \sim MVN_d(Z_{it}, \tau_Z^2 I_d)$
- Akzeptanz WK:  $\frac{f(y|Z^*, x, \beta_t) \phi_d(Z_i^*; \mu_{K_i}, \sigma_{K_i}^2 I_d)}{f(y|Z_t, x, \beta_t) \phi_d(Z_{it}; \mu_{K_i}, \sigma_{K_i}^2 I_d)}$

## Metropolis-Algorithmus für $\beta_{t+1}$

- Vorschlag:  $\beta^* \sim MVN_{p+1}(\beta_t, \tau_\beta^2 I_{p+1})$
- Akzeptanz WK:  $\frac{f(y|Z_{t+1}, x, \beta^*) \phi_{p+1}(\beta^*; \xi, \Psi)}{f(y|Z_{t+1}, x, \beta_t) \phi_{p+1}(\beta_t; \xi, \Psi)}$

## Gibbs-Sampling für:

$K_i, \mu_g, \sigma_g^2$  und  $\lambda_g$

# Identifizierbarkeit der Modellparameter



# Latente Positionen

- Die Likelihood hängt von den latenten Positionen nur über deren Distanzen ab
- Damit ist die Likelihood invariant gegenüber Spiegelung, Rotation und Verschiebung der latenten Positionen

## Lösung:

Suche die Parameterschätzungen mit dem geringsten erwarteten a posteriori Verlust (bzgl. der Kullback-Leibler Verlustfunktion)

$$\begin{aligned}\hat{\eta}_{MKL} &= \operatorname{argmin}_{\eta_*} E_{\eta|Y_{obs}}(KL(\eta, \eta_*)) \\ &= \operatorname{argmax}_{\eta_*} \frac{\exp(\eta_*^T E_{\eta}(Y|Y_{obs}))}{\prod_{i \neq j} (1 + \exp(\eta_{ij*}))}\end{aligned}$$

(Shortreed, Handcock, and Hoff 2006):

# Klassen Labels

- Invarianz gegenüber Permutationen der Clusterlabels
- Labelswitching Problem analog zu anderen Mixture Modellen

## Lösung:

Finde Clusterwahrscheinlichkeiten durch Minimierung des approximierten a posteriori erwarteten Verlusts (bzgl. der Kullback-Leibler Verlustfunktion) über alle möglichen Permutationen der Clusterlabels (Stephens 2000)

# Intercept/Random Effects im LCREM

- Invarianz des Intercepts und der Random Effects bzgl. einer additiven Konstanten  $c$ :


$$\delta_i^* = \delta_i + c, \forall i$$

$$\beta_0^* = \beta_0 - c$$

## Lösung:

Korrelierte Vorschlagsdichten und Block-Updates im MCMC Algorithmus des LCREM (Krivitsky et al. 2009)

# Vielen Dank für die Aufmerksamkeit!



# Quellen I

Handcock, Mark S., Adrian E. Raftery, and Jeremy M. Tantrum. 2007. "Model-Based Clustering for Social Networks." *Journal of the Royal Statistical Society: Series A (Statistics in Society)* 170 (2): 301–54.

Hoff, Peter D., Adrian E. Raftery, and Mark S. Handcock. 2002. "Latent Space Approaches to Social Network Analysis." *Journal of the American Statistical Association* 97 (460): 1090–8.

Krivitsky, Pavel N., and Mark S. Handcock. 2008. "Fitting Position Latent Cluster Models for Social Networks with Latentnet." *Journal of Statistical Software* 24 (5): 1–23.

Krivitsky, Pavel N., Mark S. Handcock, Adrian E. Raftery, and Peter D. Hoff. 2009. "Representing Degree Distributions, Clustering, and Homophily in Social Networks with Latent Cluster Random Effects Models." *Social*

*Networks* 31 (3): 204–13.

Shortreed, Susan, Mark S. Handcock, and Peter D. Hoff. 2006. “Positional Estimation Within a Latent Space Model for Networks.” *Methodology: European Journal of Research Methods for the Behavioral and Social Sciences* 2 (1): 24.

Stephens, Matthew. 2000. “Dealing with Label Switching in Mixture Models.” *Journal of the Royal Statistical Society: Series B (Statistical Methodology)* 62 (4): 795–809.